

PROPOSAL TUGAS AKHIR

EVALUASI CLAUDE SONNET 3.5 UNTUK MENGHASILKAN KODE AUTOMATION TESTING PLAYWRIGHT MENGGUNAKAN MODEL CONTEXT PROTOCOL



**RISMA SAPUTRI
22/505613/SV/21835**

**PROGRAM STUDI D4 TEKNOLOGI REKAYASA PERANGKAT LUNAK
DEPARTEMEN TEKNIK ELEKTRO DAN INFORMATIKA
SEKOLAH VOKASI
UNIVERSITAS GADJAH MADA
2025**

I. JUDUL

Penulis mengajukan “Evaluasi Claude Sonnet 3.5 Untuk Menghasilkan Kode Automation Testing Playwright Menggunakan Model Context Protocol” sebagai judul proyek akhir.

II. DESKRIPSI

Penelitian tentang *Machine Learning* (ML) untuk menghasilkan kode program sudah dimulai sejak tahun 1980-an. Perkembangan ini semakin pesat seiring dengan kemajuan teknologi ML untuk *Natural Language Processing* (NLP) dalam beberapa tahun terakhir. Terobosan besar hadir dengan munculnya *Large Language Models* (LLM) yang mampu mengubah cara pengembangan perangkat lunak. Salah satu kategori utama tugas pemrograman dengan bantuan LLM adalah *Description to Code* (D2C), yaitu menghasilkan kode program berdasarkan deskripsi dalam *natural language* [1].

Perkembangan LLM untuk melakukan tugas pemrograman membuka peluang besar dalam otomatisasi pembuatan kode. Akan tetapi, evaluasi masih diperlukan untuk memastikan bahwa kode yang dihasilkan benar-benar sesuai dengan kebutuhan pengguna. Untuk memastikan kode yang dihasilkan LLM benar-benar sesuai dengan kebutuhan, dibutuhkan mekanisme yang mampu menambah pemahaman model dengan informasi-informasi tertentu yang dibutuhkan. *Model Context Protocol* (MCP) merupakan sebuah standar protokol yang dikembangkan oleh Anthropic untuk memungkinkan LLM memperoleh informasi atau konteks tambahan dari sumber seperti *tooling*, *API*, *framework*, maupun file. MCP berperan sebagai jembatan komunikasi antara LLM dan server eksternal, sehingga model dapat mengakses data kontekstual maupun fungsi tertentu secara lebih terstruktur [2].

Dengan adanya MCP, LLM tidak hanya menghasilkan kode secara generik, tetapi juga dapat berinteraksi dengan *framework* tertentu sesuai dengan kebutuhan penggunaan. Pada penelitian ini, MCP dapat dimanfaatkan pada *framework* pengujian Playwright dengan mengimplementasi *design pattern Page Object Model* (POM). Fokus utama penelitian ini adalah untuk mengevaluasi kemampuan Claude Sonnet 3.5 dalam generasi skrip pengujian Playwright yang sesuai dengan konteks melalui MCP, sehingga dapat memberikan gambaran sejauh mana LLM mampu mendukung proses otomatisasi pengujian perangkat lunak.

Evaluasi tersebut dilakukan dengan memperhatikan beberapa aspek, antara lain *maintainability*, *readability*, serta metrik *pass@key* untuk mengukur probabilitas keberhasilan solusi dalam beberapa percobaan generasi. *Maintainability Index* (MI) merupakan salah satu metrik perangkat lunak yang banyak digunakan untuk mengukur tingkat *maintainability*. MI menggabungkan beberapa metrik perangkat lunak tradisional, termasuk *Halstead Volume*, *Cyclomatic Complexity*, dan *Lines of Code*, menjadi satu angka tunggal. Nilai MI yang lebih tinggi menunjukkan tingkat *maintainability* yang lebih baik [3]. *Readability* merujuk pada kemudahan bagi pembaca untuk memahami tujuan, alur, dan operasi dari *source code*. Kode yang memiliki tingkat *readability* tinggi akan lebih cepat dipahami, mudah ditinjau ulang, serta mengurangi risiko kesalahan ketika dilakukan pemeliharaan [4]. *Pass@k* merupakan salah satu metrik yang paling umum digunakan dalam penelitian *code generation*. Metrik ini menghitung kemungkinan bahwa setidaknya satu dari k solusi yang dihasilkan model sesuai dengan solusi yang benar atau *ground truth* [5]. Dengan demikian, *pass@k* tidak hanya memperhatikan satu hasil keluaran model, tetapi juga mempertimbangkan variasi solusi yang dihasilkan dalam beberapa percobaan generasi.

Berdasarkan uraian di atas, penelitian ini berfokus pada evaluasi kemampuan Claude Sonnet 3.5 dalam menghasilkan skrip pengujian Playwright dengan memanfaatkan *Model Context Protocol* (MCP). Evaluasi dilakukan melalui tiga aspek utama, yaitu *maintainability* untuk menilai sejauh mana skrip mudah dipelihara, *readability* untuk menilai tingkat keterbacaan kode, serta *pass@k* untuk mengukur kebenaran fungsional solusi yang dihasilkan. Dengan menggabungkan aspek kualitas kode dan akurasi fungsional, penelitian ini diharapkan dapat memberikan gambaran yang lebih komprehensif mengenai potensi LLM dalam mendukung proses otomatisasi pengujian perangkat lunak. Hasilnya akan dibandingkan dengan hasil pengkodean manual sebagai acuan untuk menilai kesesuaian hasil pengujian.

III. TECH-STACK

Berikut merupakan teknologi dan *tools* yang akan digunakan dalam penelitian ini.

1. Playwright, *framework* pengujian perangkat lunak
2. TypeScript, bahasa pemrograman yang digunakan untuk menulis skrip pengujian

3. *Page Object Model* (POM), *design pattern* dalam pengorganisasian kode pengujian
4. *Model Context Protocol* (MCP), protokol untuk menghubungkan LLM dengan *framework* eksternal
5. Claude Sonnet 3.5, model LLM yang akan digunakan untuk menghasilkan kode pengujian Playwright

IV. MITRA

Adapun mitra proyek ini adalah Lab TRPL Departemen Teknik Elektro dan Informatika Sekolah Vokasi UGM

V. DAFTAR PUSTAKA

- [1] D. G. Paul, H. Zhu, dan I. Bayley, “Benchmarks and Metrics for Evaluations of Code Generation: A Critical Review,” dalam *2024 IEEE International Conference on Artificial Intelligence Testing (AITest)*, Shanghai, China: IEEE, Jul 2024, hlm. 87–94. doi: 10.1109/AITest62860.2024.00019.
- [2] P. P. Ray, “A Survey on Model Context Protocol: Architecture, State-of-the-art, Challenges and Future Directions,” 18 April 2025, *Preprints*. doi: 10.36227/techrxiv.174495492.22752319/v1.
- [3] T. Heričko dan B. Šumak, “Exploring Maintainability Index Variants for Software Maintainability Measurement in Object-Oriented Systems,” *Applied Sciences*, vol. 13, no. 5, hlm. 2972, Feb 2023, doi: 10.3390/app13052972.
- [4] D. Oliveira, R. Bruno, F. Madeiral, dan F. Castor, “Evaluating Code Readability and Legibility: An Examination of Human-centric Studies,” dalam *2020 IEEE International Conference on Software Maintenance and Evolution (ICSME)*, Adelaide, Australia: IEEE, Sep 2020, hlm. 348–359. doi: 10.1109/ICSME46990.2020.00041.
- [5] J. Liu, C. S. Xia, Y. Wang, dan L. Zhang, “Is Your Code Generated by ChatGPT Really Correct?,” 2023.