

PROPOSAL TUGAS AKHIR

PROGRAM STUDI TEKNOLOGI REKAYASA PERANGKAT LUNAK

A. Judul

Pengembangan *Chatbot* Berbasis *Retrieval-Augmented Generation* (RAG) Menggunakan Framework N8N Untuk Mendukung Pengambilan Keputusan Proses Bisnis Perusahaan.

B. Rumusan Masalah

- 1) Bagaimana memanfaatkan dokumen proses bisnis perusahaan yang tersimpan dan terstruktur di *Google Drive* sebagai sumber pengetahuan untuk membangun sistem RAG?
- 2) Bagaimana mengembangkan sebuah *chatbot* berbasis RAG yang dapat meningkatkan kolaborasi dan aksesibilitas informasi lintas divisi dalam perusahaan?
- 3) Bagaimana sistem *chatbot* RAG dapat membantu meminimalkan risiko ketidakpatuhan (*non-compliance*) dalam proses pengambilan keputusan bisnis agar sesuai dengan kebijakan dan tata kelola perusahaan?

C. Deskripsi

Penelitian ini bertujuan merancang sebuah solusi sistem cerdas untuk mengatasi tantangan mendasar dalam manajemen pengetahuan di lingkungan perusahaan. Fokus utama penelitian terletak pada Informasi Arsitektur Perusahaan, yang mencakup berbagai dokumen tata kelola (*governance*), kebijakan, standar operasional, serta prosedur proses bisnis yang menjadi basis utama pengambilan keputusan. Pentingnya struktur tata kelola yang baik dalam arsitektur sistem informasi perusahaan berbasis RAG juga telah ditekankan dalam penelitian terbaru [2].

Permasalahan utama yang melatarbelakangi penelitian ini adalah kondisi umum di banyak organisasi, di mana dokumen-dokumen penting tersebut tersebar di berbagai repositori tiap divisi, tidak terstruktur dengan baik, dan sulit diakses secara efisien. Situasi ini mengakibatkan karyawan harus menghabiskan waktu signifikan untuk menemukan informasi yang relevan, bahkan terkadang menggunakan dokumen yang telah kedaluwarsa. Hal tersebut tidak hanya memperlambat proses pengambilan

keputusan strategis, tetapi juga meningkatkan risiko ketidakpatuhan (*non-compliance*) terhadap kebijakan yang berlaku. Tantangan serupa dalam hal aksesibilitas informasi yang akurat dan *real-time* juga ditemukan dalam sektor hukum, di mana AI digunakan untuk memberikan wawasan yudisial yang cepat dan tepat [4].

Solusi yang diajukan adalah implementasi arsitektur *Retrieval-Augmented Generation* (RAG). Sebagaimana didefinisikan oleh Lewis *et al.*, RAG merupakan metode yang meningkatkan kemampuan *Large Language Model* (LLM) dengan mengintegrasikan mekanisme pencarian (*retrieval*) informasi dari sumber pengetahuan eksternal [1]. Pendekatan ini secara efektif mengatasi keterbatasan LLM konvensional, seperti kecenderungan menghasilkan informasi yang tidak akurat (halusinasi) dan ketidakmampuan mengakses data privat maupun *real-time* perusahaan.

Efektivitas RAG telah terbukti di berbagai domain, mulai dari penggunaannya sebagai alat pembelajaran inovatif di pendidikan tinggi [3] hingga peningkatan layanan dukungan pelanggan di sektor *e-commerce* [5]. Mengadopsi keberhasilan integrasi teknologi tersebut, penelitian ini memanfaatkan *framework low-code n8n* sebagai alat *orchestrator* alur kerja (*workflow orchestration tool*) untuk mengelola kompleksitas arsitektur RAG secara efisien.

Sistem yang dikembangkan terdiri dari dua alur kerja (*pipeline*) n8n yang fundamental. Alur kerja pertama adalah *Data Ingestion Pipeline*, yang bertugas membangun dan memelihara basis pengetahuan (*knowledge base*) secara otomatis. Alur ini dipicu (*trigger*) setiap kali ada dokumen baru yang dibuat (*Google Drive File Created*) atau dokumen yang ada diperbarui (*Google Drive File Updated*). Setelah terpicu, n8n mengunduh file tersebut, memecahnya menjadi bagian-bagian teks yang lebih kecil (*chunking*) menggunakan *Recursive Character Text Splitter*, lalu mengubah setiap bagian menjadi representasi vektor numerik melalui node “*Embeddings Google Gemini*”.

Vektor-vektor semantik ini kemudian diunggah dan disimpan ke dalam *database* vektor *Pinecone Vector Store*, memastikan basis pengetahuan selalu sinkron dengan data terkini. Alur kerja kedua adalah *Query Pipeline with LLM*, yang berfungsi sebagai antarmuka

interaktif bagi pengguna akhir. Ketika pengguna mengirimkan pertanyaan (*When chat message received*), alur ini mengaktifkan *AI Agent* yang bertindak sebagai otak pemroses utama. *Agent* ini memanfaatkan *Vector Store Tool* untuk terlebih dahulu mengubah pertanyaan pengguna menjadi vektor (menggunakan *Embeddings Google Gemini (retrieval)*). Vektor pertanyaan ini digunakan untuk mencari konteks yang paling relevan dari *Pinecone Vector Store* (proses *Retrieval*). Konteks yang didapat dari dokumen perusahaan ini, bersama dengan riwayat percakapan (*Window Buffer Memory*), kemudian diberikan kepada “*Google Gemini Chat Model*” untuk menyusun jawaban akhir (proses *Generation*) yang akurat, faktual, dan didasarkan pada sumber data internal yang terverifikasi.

D. Matriks Penilaian

1) Kebenaran (*Factuality*)

Metrik *factuality* mencakup akurasi faktual, *groundedness*, *truthfulness*, serta tingkat halusinasi (*hallucination rate*). Metrik ini berfungsi untuk menilai sejauh mana jawaban yang dihasilkan model benar-benar didasarkan pada fakta yang valid, merujuk pada sumber yang jelas, dan tidak menambahkan informasi yang tidak terdapat dalam basis pengetahuan (*fabricated facts*). Dalam konteks RAG, tingkat *groundedness* sangat penting karena model diharapkan menjawab berdasarkan dokumen perusahaan, bukan dari pengetahuan umum atau prediksi model semata. Oleh karena itu, evaluasi *factuality* dilakukan dengan memeriksa:

- Konsistensi jawaban terhadap dokumen sumber.
- Akurasi informasi yang dikutip.
- Ketiadaan fakta palsu (*fabricated facts*) atau spekulasi.
- Rendahnya tingkat halusinasi atau pernyataan tanpa dasar.

2) Keterampilan Berbicara & Kelancaran (*Fluency & Coherence*)

Metrik *fluency* dan *coherence* digunakan untuk menilai kualitas bahasa yang dihasilkan model. *Fluency* menggambarkan kelancaran dan kealamian penggunaan bahasa, mencakup tata bahasa, pemilihan diksi, dan struktur kalimat. Sementara itu, *coherence* menilai alur logis dan keterkaitan antar-kalimat

sehingga jawaban tidak terputus, tidak ambigu, dan mudah dipahami. Evaluasi metrik ini dilakukan dengan memperhatikan:

- Kelancaran dan kejelasan kalimat.
- Konsistensi alur ide dari awal hingga akhir.
- Struktur paragraf yang tersusun rapi dan tidak kontradiktif.
- Kejelasan konteks dan tidak adanya penyimpangan pembahasan.

Metrik ini memastikan bahwa jawaban yang diberikan bukan hanya benar secara fakta, tetapi juga komunikatif dan mudah pahami oleh pengguna.

3) Kesesuaian & Kemanfaatan (*Relevance & Usefulness*)

Metrik *relevance* dan *usefulness* menilai sejauh mana jawaban model sesuai dengan maksud pertanyaan pengguna. *Relevance* mengukur keterkaitan langsung antara isi jawaban dan *prompt*, memastikan tidak ada bagian yang tidak relevan, mengada-ada, atau keluar konteks. Sementara *usefulness* menilai apakah jawaban tersebut benar-benar membantu pengguna dalam menyelesaikan tugas atau membuat keputusan.

E. Tools & Tech Stack

Nama Tools	Keterangan
N8N	Berfungsi sebagai "tulang punggung" (<i>backbone</i>) sistem yang mengorkestrasi seluruh alur kerja otomatisasi. n8n digunakan untuk menghubungkan berbagai layanan terpisah (Google Drive, Pinecone, Gemini) melalui antarmuka visual berbasis node. Dalam penelitian ini, n8n bertanggung jawab mengelola dua pipeline utama: <i>Data Ingestion</i> (ekstraksi dan transformasi data) serta <i>Query Processing</i> (penanganan permintaan pengguna dan manajemen memori percakapan).
Google Gemini AI <i>agent</i>	Sebagai model bahasa (LLM) yang sebagai komponen inti kecerdasan sistem. Model <i>Embeddings</i> digunakan untuk mengonversi dokumen dan pertanyaan pengguna menjadi representasi vektor semantik, sedangkan

	<i>Model Chat</i> digunakan pada tahap <i>generation</i> untuk menghasilkan respons yang kontekstual, akurat, dan berbasis data hasil <i>retrieval</i> dari <i>vector store</i> .
Pinecone Vector Database	Basis data vektor berbasis <i>cloud (serverless)</i> yang dirancang untuk menyimpan dan mengelola indeks vektor berdimensi tinggi. Pinecone berfungsi sebagai memori jangka panjang sistem, memungkinkan pencarian kemiripan (<i>similarity search</i>) yang sangat cepat dan akurat untuk menemukan fragmen dokumen yang relevan.
Google Drive	Repositori penyimpanan data utama tempat dokumen proses bisnis (SOP, Kebijakan, Instruksi Kerja) disimpan. Sistem mengakses repositori ini secara programatik melalui Google Drive API untuk mendeteksi perubahan file (<i>trigger</i>), mengunduh konten dokumen, dan memastikan basis pengetahuan RAG selalu tersinkronisasi dengan versi dokumen terbaru.

F. Mitra / Perusahaan

PT. Global Data Inspirasi

G. Daftar Pustaka

- [1] P. Lewis et al., "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks," arXiv preprint arXiv:2005.11401, May 2020. [Online]. Available: <https://arxiv.org/abs/2005.11401>
- [2] C. Kesuma, "Retrieval Augment Generation (RAG) Governance Architecture for Enterprise Information Systems," International Journal of Informatics, Economics, Management and Science (IJIEMS), vol. 4, no. 2, pp. 133-142, Aug. 2025. doi: 10.52362/ijiems.v4i2.2051.
- [3] H. Irawan, "Utilizing Retrieval Augmented Generation (RAG)-Based Chatbots as an Innovative Learning Tool in Higher Education: A Case Study on the Use of

Digital Learning Resources," Oct. 2025. [Online]. Available: <https://www.google.com/search?q=https://www.researchgate.net/publication/397094598>

- [4] S. Vijayakumaran et al., "Revolutionizing Legal Access: An AI-Driven RAG Chatbot for Real-Time Judicial Insights," in 2025 3rd International Conference on Artificial Intelligence and Machine Learning Applications (AIMLA), 2025, pp. 1-6. doi: 10.1109/AIMLA63829.2025.11040439.

- [5] J. Benita, K. V. C. Tej, E. V. Kumar, G. V. Subbarao, and C. Venkatesh, "Implementation of Retrieval-Augmented Generation (RAG) in Chatbot Systems for Enhanced Real-Time Customer Support in E-Commerce," in 2024 3rd International Conference on Automation, Computing and Renewable Systems (ICACRS), Pudukkottai, India, 2024. doi: 10.1109/ICACRS62842.2024.10841586.