

PROPOSAL
PROFILING PENGGUNA PENYEBAR HATE SPEECH DENGAN
NATURAL LANGUAGE PROCESSING (NLP) DAN MODEL KLASIFIKASI



Disusun oleh:
ISAN FAIZUN HIDAR
22/500411/SV/21417

PROGRAM STUDI SARJANA TERAPAN
TEKNOLOGI REKAYASA PERANGKAT LUNAK
DEPARTEMEN TEKNIK ELEKTRO DAN INFORMATIKA
SEKOLAH VOKASI
UNIVERSITAS GADJAH MADA
YOGYAKARTA
2025

DAFTAR ISI

BAB 1	PENDAHULUAN	3
1.1	Latar Belakang	3
1.2	Rumusan Masalah	4
1.3	Alternatif Penyelesaian	4
1.4	Justifikasi Cara Penyelesaian Masalah	5
1.5	Tujuan dan Manfaat Proyek Akhir	5
BAB 2	LANDASAN TEORI	6
2.1	Lingkup Tinjauan Pustaka	6
BAB 3	METODE PROYEK AKHIR	6
3.1	Bahan	6
3.2	Peralatan	6
3.3	Tahapan Proyek Akhir	6
DAFTAR PUSTAKA		7

BAB 1 PENDAHULUAN

1.1 Latar Belakang

Secara umum, ujaran kebencian atau *hate speech* merupakan ungkapan yang secara sengaja merendahkan atau menghina individu maupun kelompok, baik secara implisit atau eksplisit atas dasar karakteristik sosial-kelompok yang melekat atau diasosiasikan pada mereka. Lebih lanjut, ujaran kebencian tidak harus menyerang karakteristik yang sebenarnya dimiliki target yang dijadikan bahan sebagai *hate speech*, melainkan bisa dengan menyerang stereotipnya atau persepsi sosial terhadapnya (Castellanos et al., 2023). Salah satu platform yang digunakan pelaku dalam melakukan aksi ujaran kebencian adalah X (dulu Twitter), yang mana dapat memicu adanya konflik dan polarisasi. Terlebih lagi, jumlah konten yang mengandung *hate speech* ini ada banyak, sehingga membuatnya menjadi sulit untuk dilakukan identifikasi secara manual (Perera et al., 2023).

Akan tetapi, pengelompokan terkait konten yang positif dan negatif *hate speech* tidak cukup. Oleh karena itu, munculah sebuah gagasan mengenai proses identifikasi terhadap pengguna yang membagikan atau menyebarkan konten *hate speech* tersebut. Proses identifikasi pengguna ini disebut sebagai *profiling*. Hal ini perlu dilakukan karena pada dasarnya para penyebar konten tersebut memiliki peran, baik kecil atau besar, dalam memperbesar sebuah konflik. Gagasan ini muncul pada tahun 2021 pada konferensi yang diadakan oleh CLEF. Kemudian, dengan melakukan identifikasi dini terhadap akun-akun tersebut, platform media sosial dapat mencegah penyebaran ujaran kebencian secara lebih efektif dan mendukung kebijakan moderasi konten yang berkelanjutan (Jain et al., 2021).

Adapun beberapa hasil dari penelitian yang diadakan pada konferensi tersebut. Penelitian pertama menyatakan bahwa identifikasi otomatis terhadap penyebar ujaran kebencian (*hate speech spreaders*) di platform X dapat dilakukan dengan tingkat akurasi yang tinggi (Rangel et al., 2021). Kemudian, penelitian kedua menyatakan jika sistem dapat dimanfaatkan dapat membantu proses moderasi menggunakan pendekatan yang mengombinasikan model natural language process (NLP) dan model klasifikasi (Jain et al., 2021).

Berdasarkan hasil penelitian tersebut, maka dibutuhkan penelitian terkait pembuatan model untuk dilakukan profiling terhadap para penyebar konten yang bertemakan hate speech. Melalui model tersebut, sistem dapat melakukan identifikasi pola bahasa yang khas dari akun-akun yang cenderung menyebarkan hate speech. Kemudian, penelitian ini tentunya memiliki tujuan untuk meneruskan pengembangan terkait profiling terhadap penyebar konten hate speech dan diharapkan supaya dapat menciptakan ruang digital yang lebih aman dan sehat melalui sistem pencegahan dini terhadap ujaran kebencian.

1.2 Rumusan Masalah

Rumusan masalah ini dikemukakan secara lebih spesifik berdasarkan latar belakang yang dijelaskan sebelumnya. Berikut adalah rumusannya:

1. Apakah terdapat perbedaan karakteristik kosakata yang digunakan antara pengguna yang menyebarkan ujaran kebencian dan yang tidak?
2. Model apa saja yang paling efektif dalam melakukan proses klasifikasi mana konten yang bersifat hate speech atau yang tidak
3. Bagaimana proses profiling penyebar ujaran kebencian di media sosial?
4. Bagaimana tingkat akurasi dari model yang dibangun?

1.3 Alternatif Penyelesaian

Natural language process (NLP) merupakan kegiatan untuk memproses, memahami, dan menghasilkan bahasa alami manusia dari sebuah data berupa teks. Proses ini umumnya dapat mengenali struktur sintaksis seperti kata, klausa, frasa, hingga kalimat dan dapat memahami maknanya secara semantik (Hupkes et al., 2023). Beberapa metode dalam melakukan pemrosesan teks ini adalah seperti named entity recognition (NER), text embeddings, text summarization, dan tokenization (Sawicki et al., 2023).

Model klasifikasi adalah model yang akan memprediksi data baru berdasarkan kategori yang sebelumnya sudah ditentukan. Sebelum model dapat memprediksi, terdapat tahapan training terlebih dahulu dengan data-data yang sudah dilabeli. Kemudian, karena tahapan training-nya dilakukan pada data yang sudah dilabeli, maka model klasifikasi disebut sebagai supervised learning. Contoh model klasifikasi adalah logistic regression, decision tree, random forest, k-nearest

neighbour, SVM, dan lain-lain (Black et al., 2023). Adapun model klasifikasi yang menggunakan deep learning untuk kasus yang berhubungan dengan NLP seperti LSTM, Bi-LSTM, dan BERT (Jain et al., 2021).

1.4 Justifikasi Cara Penyelesaian Masalah

Alasan utama terkait mengapa harus menggunakan kombinasi antara NLP dan model klasifikasi adalah sebagai berikut (Rengel et al., 2021):

1. NLP digunakan untuk memahami makna semantik dan sintaksis dari suatu teks, lalu mengubahnya menjadi satu kesatuan teks, yang umumnya berupa numerik, supaya bisa diproses oleh mesin.
2. Model klasifikasi digunakan untuk pengambilan keputusan dan dikarenakan oleh dataset yang bentuk prediksinya berupa kategori.

1.5 Tujuan dan Manfaat Proyek Akhir

Tujuan dari adanya penelitian ini adalah sebagai berikut:

1. Menunjukkan kelayakan identifikasi otomatis terhadap pengguna yang berpotensi menjadi penyebar ujaran kebencian.
2. Menganalisis efektivitas berbagai metode NLP dan model klasifikasi dalam mengidentifikasi penyebar ujaran kebencian.
3. Mendukung upaya pencegahan penyebaran ujaran kebencian di media sosial dengan memberikan dasar untuk identifikasi dini terhadap akun yang berpotensi menyebarkan kebencian.

Selain beberapa tujuan di atas, terdapat manfaat yang bisa diambil dari penelitian ini, yaitu dapat membantu pihak platform media sosial, peneliti, dan pembuat kebijakan dalam mengidentifikasi akun-akun yang berpotensi menyebarkan ujaran kebencian, sekaligus menjadi dasar pengembangan sistem atau aplikasi deteksi otomatis untuk mendukung moderasi konten secara lebih efektif. Selain itu, hasil penelitian ini juga berkontribusi dalam menciptakan ruang digital yang lebih sehat dengan meminimalisir penyebaran ujaran kebencian, sehingga interaksi di media sosial dapat berlangsung secara aman, toleran, dan bertanggung jawab.

BAB 2 LANDASAN TEORI

2.1 Lingkup Tinjauan Pustaka

2.2 Dasar Teori

2.3 Hipotesis

BAB 3 METODE PROYEK AKHIR

3.1 Bahan

3.2 Peralatan

3.3 Tahapan Proyek Akhir

DAFTAR PUSTAKA

- Black, J. E., Kueper, J. K., & Williamson, T. S. (2023). An introduction to machine learning for classification and prediction. *Family Practice*, 40(1), 200–204. <https://doi.org/10.1093/fampra/cmac104>
- Castellanos, M., Wettstein, A., Wachs, S., Kansok-Dusche, J., Ballaschk, C., Krause, N., & Bilz, L. (2023). Hate speech in adolescents: A binational study on prevalence and demographic differences. *Frontiers in Education*, 8, 1076249.
- Hupkes, D., Giulianelli, M., Dankers, V., Artetxe, M., Elazar, Y., Pimentel, T., Christodoulopoulos, C., Lasri, K., Saphra, N., Sinclair, A., Ulmer, D., Schottmann, F., Batsuren, K., Sun, K., Sinha, K., Khalatbari, L., Ryskina, M., Frieske, R., Cotterell, R., & Jin, Z. (2023). A taxonomy and review of generalization research in NLP. *Nature Machine Intelligence*, 5(10), 1161–1174.
- Jain, R., Goel, D., Sahu, P., Kumar, A., & Singh, J. P. (2021). *Profiling Hate Speech Spreaders on Twitter*. 2011–2024.
- Perera, S., Meedin, N., Caldera, M., Perera, I., & Ahangama, S. (2023). A comparative study of the characteristics of hate speech propagators and their behaviours over Twitter social media platform. *Heliyon*, 9(8), e19097.
- Rangel, F., Peña-Sarracén, G. L. de la, Chulvi-Ferriols, M. A., Fersini, E., & Rosso, P. (2021). *Profiling hate speech spreaders on twitter task at PAN 2021*. 1772–1789.
- Sawicki, J., Ganzha, M., & Paprzycki, M. (2023). The State of the Art of Natural Language Processing—A Systematic Automated Review of NLP Literature Using NLP Techniques. *Data Intelligence*, 5(3), 707–749. https://doi.org/10.1162/dint_a_00213