

PROPOSAL TUGAS AKHIR

- Judul : APLIKASI PENDETEKSI UJARAN KEBENCIAN BERBAHASA INDONESIA DI MEDIA SOSIAL X (TWITTER) MENGGUNAKAN ALGORITMA INDOBERT

- Deskripsi :

Peningkatan penggunaan media sosial Twitter (sekarang X) di Indonesia telah mendorong meningkatnya opini/komentar publik, tak terkecuali ujaran kebencian. Berbagai penelitian terkini menunjukkan bahwa intensitas ujaran kebencian daring di Indonesia meningkat signifikan dalam dua tahun terakhir, terutama menjelang dan selama periode politik seperti pemilihan presiden, sehingga hal ini berpotensi menjadi ancaman serius bagi keharmonisan sosial dan keamanan digital (Susanto et al., 2024). Untuk itu, diperlukan sebuah sistem pendeteksi otomatis ujaran kebencian menggunakan algoritma *Machine Learning/Deep Learning* untuk mengurangi keterbatasan kemampuan manusia dan bias pengguna, serta dapat digunakan oleh pihak terkait yang bersinggungan dengan komentar ujaran kebencian.

Penggunaan metode *Machine Learning* klasik pada penelitian terdahulu memiliki berbagai tantangan. Penelitian terdahulu telah menunjukkan bahwa penelitian semacam itu sering terhambat oleh terbatasnya jumlah data berlabel, distribusi kelas yang tidak seimbang, dan minimnya penggunaan model *transformer* terbaru dalam eksperimen (Ibrohim & Budi, 2019). Untuk itu, dibutuhkan model deteksi berbasis *transformer* yang lebih adaptif dan efisien seperti IndoBERT. IndoBERT merupakan model pre-trained berbasis BERT yang dilatih secara monolingual menggunakan korpus besar bahasa Indonesia, seperti Wikipedia, berita, media sosial, dan web dengan arsitektur yang mengikuti BERT-base (12 lapisan, 768 dimensi, 12 attention heads) dan juga tersedia dalam varian large dan lite, sehingga mampu memahami nuansa, bahasa gaul, dan variasi gaya bahasa Indonesia lebih baik daripada model lainnya (Wilie et al., 2020). Model berbasis *transformer* seperti IndoBERT dan IndoBERTweet menunjukkan kinerja deteksi yang sangat kuat ketika diterapkan pada data Twitter Indonesia, dengan akurasi mencapai sekitar 93% dan skor F1 di atas 0,85 (Bagestra et al., 2024).

Penelitian ini mengusulkan penggunaan model berbasis IndoBERT sebagai sistem deteksi yang lebih adaptif dan kuat dalam memahami teks berbahasa Indonesia. Penelitian ini mengembangkan model deteksi ujaran kebencian berbasis IndoBERT

yang di-*fine-tuning* menggunakan dataset publik dari penelitian Ibrohim dan Budi (2019). Dataset meliputi 13,169 data dengan multi-label sebanyak 12 yang terbagi atas label bahasa kasar, ujaran kebencian, target, kategori, dan level. Target ujaran kebencian dibagi menjadi individu dan kelompok. Kategori ujaran kebencian meliputi: Religion/creed, Race/ethnicity, Physical/disability, Gender/sexual orientation, dan Other invective/slander. Level ujaran kebencian dibagi menjadi weak, moderate, dan strong. Selain itu, penelitian ini juga mengembangkan aplikasi berbasis web untuk melakukan analisis dan prediksi multi-label pada berbagai *tweet* yang disinyalir mengandung ujaran kebencian/bahasa secara *real-time*.

- Tools/ Tech Stack : Python, Google Collaboratory, Flask, Streamlit
- Mitra/ Perusahaan : Lab RPL
- Daftar Pustaka :

Bagestra, R., Misbullah, A., Zulfan, Z., Rasudin, R., Farsiah, L., & Nazhifah, S. A. (2024). Performance assessment of machine learning and transformer models for Indonesian Multi-Label Hate Speech Detection. *Infolitika Journal of Data Science*, 2(2), 62–71. <https://doi.org/10.60084/ijds.v2i2.235>.

Ibrohim, M. O., & Budi, I. (2019). Multi-label Hate Speech and Abusive Language Detection in Indonesian Twitter. *Proceedings of the Third Workshop on Abusive Language Online*. <https://doi.org/10.18653/v1/w19-3506>.

Susanto, L., Wijanarko, M. I., Pratama, P. A., Hong, T., Idris, I., Aji, A. F., & Wijaya, D. (2024, June 27). *IndoToxic2024: A Demographically-Enriched Dataset of Hate Speech and Toxicity Types for Indonesian Language*. arXiv.org. <https://arxiv.org/abs/2406.19349>.

Wilie, B., Vincentio, K., Winata, G. I., Cahyawijaya, S., Li, X., Lim, Z. Y., Soleman, S., Mahendra, R., Fung, P., Bahar, S., & Purwarianti, A. (2020). IndoNLU: Benchmark and Resources for Evaluating Indonesian Natural Language Understanding. *Association for Computational Linguistics*, 843–857. <https://doi.org/10.18653/v1/2020.aacl-main.85>.