

Desain dan Pengembangan Sistem RAG untuk Analisis Keterbukaan Informasi IDX sebagai *Copilot* Investasi

Oleh: Muhammad Rizky Aziz (22/499420/SV/21321)

Dosen Pembimbing: Irkham Huda, S.Kom., M.Cs.s

1. Deskripsi

Analisis data keuangan seperti dokumen keterbukaan informasi dari Indonesia *Stock Exchange* (IDX) sering kali mengalami kendala karena tidak terstruktur dan volume data yang besar. Hal tersebut dapat menyebabkan keterlambatan dalam pengambilan informasi dan berpotensi mengurangi keuntungan atau bahkan menyebabkan kerugian pada pelaku investasi. Teknologi AI yang berkembang saat ini terutama *Large Language Models* (LLMs) menjadi pilihan utama untuk membantu menganalisis keterbukaan informasi. Namun, temuan penelitian terbaru menunjukkan bahwa LLM cenderung menghasilkan halusinasi atau konten yang menyimpang dari konteks sebelumnya atau pengetahuan faktual. Hal tersebut menjadi tantangan utama dalam keandalan LLM untuk skenario dunia nyata, termasuk pengambilan keputusan dalam investasi [1].

Retrieval Augmented Generation (RAG) merupakan salah satu pendekatan yang banyak digunakan untuk mengatasi masalah halusinasi dan meningkatkan akurasi dalam pemrosesan data finansial. Pendekatan ini menggabungkan pengambilan informasi dari sumber eksternal dengan generasi teks berbasis LLM. Sehingga, model dapat mengakses data di luar pelatihannya dan menghasilkan respons yang lebih faktual serta kontekstual. Kajian dari berbagai penelitian menunjukkan bahwa RAG memberikan pengaruh positif signifikan terhadap performa analisis data keuangan, di mana elemen seperti *chunking* dokumen, *embedding* vektor, dan *re-ranking* konteks menjadi mekanisme utama yang digunakan dalam bidang *fintech* [2], [3].

Dalam sistem yang dirancang, RAG akan diterapkan melalui beberapa elemen utama. Dokumen keuangan seperti dokumen keterbukaan informasi dipecah menjadi *chunks* berdasarkan struktur (semantik) untuk meningkatkan relevansi dalam *retrieval*. Lalu konteks disimpan di basis data vektor menggunakan model *embedding* seperti MiniLM. *Retrieval* dilakukan dengan mengolah ulang *query*, memecahnya menjadi *sub-query*, lalu menyusun ulang hasilnya dengan *cross-encoder* agar konteks yang diperoleh lebih relevan. Generasi respons dilakukan dengan menggunakan LLM seperti

Llama untuk menghasilkan informasi seperti anomali, tren, dan penarikan poin-poin kunci yang relevan bagi analisis. Proses penilaian halusinasi dilakukan dengan beberapa metrik untuk memastikan hasil tetap andal. Pendekatan ini terbukti membantu mengurangi halusinasi, meningkatkan akurasi, dan memberikan pengalaman analisis yang lebih jelas serta lebih bermanfaat bagi para pelaku investasi [1], [4].

Studi lain juga menekankan pentingnya pendekatan RAG yang adaptif untuk bidang keuangan. Dengan menyesuaikan proses *chunking* berdasarkan bagian dokumen serta menambahkan modul *agentic* untuk memahami *query*, sistem dapat mempertahankan keandalan lebih baik dibandingkan LLM yang berdiri sendiri. Penelitian membuktikan bahwa RAG mampu meningkatkan relevansi konteks, mengurangi *latency*, serta memberikan analisis *real-time* yang lebih akurat untuk keputusan seperti alokasi aset dan mitigasi risiko [5], [6].

Dalam konteks *copilot* investasi untuk analisis dokumen keterbukaan informasi, dibutuhkan sistem yang dapat mengelola data tidak terstruktur, *query* interaktif, serta evaluasi otomatis secara terpusat. Pendekatan berbasis RAG telah terbukti memudahkan integrasi layanan analisis keuangan semacam ini, berkat desainnya yang modular, mudah diskalakan, dan memisahkan logika pencarian data dari proses pembuatan respons [2], [3]. Oleh karena itu, tugas akhir ini berfokus pada desain dan pengembangan sistem RAG untuk analisis dokumen keterbukaan informasi, yang mencakup pemrosesan data, sistem RAG inti Pembuatan sehingga diharapkan dapat mendukung keputusan dan aksi cerdas bagi investor di sektor fintech.

2. Matriks Evaluasi

- a. Perbandingan model LLM yang digunakan dan pengaruhnya terhadap akurasi retrieval (Precision, Recall, F1).
- b. *Inter-rater agreement* menggunakan *Cohen's Kappa* antara sistem dengan salah satu anotator, serta satu anotator dengan anotator lainnya.
- c. Perbandingan tingkat halusinasi model LLM yang berdiri sendiri dengan sistem RAG

3. Tools/Tech Stack

Pengembangan sistem ini memanfaatkan berbagai perangkat lunak dan teknologi untuk mendukung proses perancangan, implementasi, hingga pengujian. Adapun tools dan tech stack yang digunakan adalah sebagai berikut:

- all-MiniLM-L6-v2 - model *embedding* untuk menghasilkan representasi vektor dari teks.
- Ollama - platform untuk menjalankan dan mengelola model LLM secara lokal.
- FAISS - pustaka pencarian vektor berkecepatan tinggi untuk melakukan *indexing* dan *retrieval*.
- FastAPI - kerangka kerja backend berbasis Python untuk membangun layanan API yang cepat dan efisien.
- Next.js - kerangka kerja React untuk pengembangan antarmuka web yang interaktif dan responsif.

4. Mitra

Topik ini bekerja sama dengan PT Nusa Quanta Indonesia, perusahaan yang bergerak di bidang kecerdasan buatan dan perangkat lunak. PT Nusa Quanta Indonesia berfokus pada pengembangan solusi berbasis data untuk mendukung analisis, manajemen risiko, dan pengambilan keputusan yang lebih presisi. Melalui kemitraan ini, penelitian mendapatkan gambaran nyata tentang kebutuhan industri dalam mengolah dan menganalisis data finansial secara efektif, sehingga sistem yang dikembangkan dapat lebih relevan dan bermanfaat dalam praktik.

5. Daftar Pustaka

- [1] T. Fu, X. Huang, E. Zhao, Y. Zhang, and Y. Chen, "Siren's Song in the AI Ocean: A Survey on Hallucination in Large Language Models," 2023, doi: <https://doi.org/10.48550/arXiv.2309.01219>.
- [2] S. Roychowdhury, A. Alvarez, B. Moore, M. Crema, M. P. Gelpi, and F. Mart, "Hallucination-minimized Data-to-answer Framework for Financial Decision-makers," p. 11, 2023, doi: <https://doi.org/10.48550/arXiv.2311.07592>.
- [3] R. Osuagwu, L. Tsatiashvili, V. Vrynsia, K. Ghosal, M. Masoud, and R. Mattivi, "Retrieval Augmented Generation (RAG) for Fintech : Agentic Design and Evaluation," 2025, doi: <https://doi.org/10.48550/arXiv.2510.25518>.
- [4] I. Iaroshev, R. Pillai, L. Vaglietti, and T. Hanne, "applied sciences Evaluating Retrieval-Augmented Generation Models for Financial Report Question and Answering," 2024, doi: <https://doi.org/10.3390/app14209318>.
- [5] P. Tailor, "Investi Generation (RAG) for Real- Time Financial Market

Analysis,” vol. 07, no. 137, pp. 137–144, 2025, doi:
10.37547/tajiir/Volume07Issue07-12.

- [6] L. Jimeno, Antonio; Yepes; You, Yao; Milczek, Jan; Sebastian Laverde; Li,
“Financial Report Chunking for Effective Retrieval Augmented Generation,” p.
15, 2024, doi: <https://doi.org/10.48550/arXiv.2402.05131>.